

Reporte Final del Sistema de Análisis Automático con Machine Learning

Fecha de generación: 21/05/2026 18:31:02

Archivo analizado: dataset_unido_preparado.csv

1. Descripción del problema

El objetivo del análisis es construir un flujo automático de Machine Learning para preparar datos, transformar variables, segmentar registros mediante clustering y comparar modelos de clasificación. En este caso, el problema se orienta a predecir si un estudiante presenta una respuesta positiva, interpretada como aprobación o desempeño suficiente.

2. Preparación y unión de datasets

Indicador	Valor
Cantidad de archivos	2
Filas originales acumuladas	1044
Filas dataset unido	1044
Columnas dataset unido	35
Valores nulos	0
Duplicados	0

Se cargaron múltiples datasets relacionados y se integraron en una sola base de datos. La unión fue válida porque los archivos tenían la misma estructura de columnas. Además, se agregó una columna de origen para identificar de qué archivo proviene cada registro.

3. Creación de variable objetivo

Se creó la variable objetivo **respuesta_positiva**. Para el caso académico, esta variable se genera a partir de la nota final G3: si G3 es mayor o igual a 10, se considera respuesta positiva; si G3 es menor que 10, se considera respuesta negativa.

Valor	Interpretación
1	Respuesta positiva / estudiante aprobado
0	Respuesta negativa / estudiante no aprobado

4. Prevención de data leakage

Columna	Motivo	Acción
G1	Nota previa muy relacionada con el resultado final.	Excluir de las variables predictoras
G2	Nota previa muy relacionada con el resultado final.	Excluir de las variables predictoras
G3	Fue utilizada para construir la variable objetivo.	Excluir de las variables predictoras

El data leakage ocurre cuando el modelo recibe información que no debería conocer en un escenario real de predicción. Por ello, las columnas identificadas como riesgo fueron excluidas antes del entrenamiento para obtener una evaluación más realista.

5. Resumen del dataset original

Indicador	Valor
Filas originales	1044
Columnas originales	35
Valores nulos originales	0
Filas duplicadas originales	0

6. Limpieza de datos

Indicador	Valor
Filas después de limpieza	1044
Columnas después de limpieza	32
Valores nulos finales	0
Duplicados finales	0

Se aplicó limpieza de datos considerando eliminación de duplicados, tratamiento de valores nulos y exclusión de columnas no recomendadas para el modelado.

7. Transformación de datos

Indicador	Valor
Filas transformadas	1044
Columnas transformadas	59
Valores nulos	0

Se aplicó codificación de variables categóricas y escalado de variables numéricas. Para este caso académico se recomienda One-Hot Encoding, debido a que muchas variables categóricas son nominales y no poseen un orden natural.

8. Segmentación con clustering

Algoritmo utilizado: K-Means


Registros segmentados: 1044

Número de clusters generados: 3

Silhouette Score: 0.0662

Interpretación: los clusters no están claramente separados.

Cluster	Cantidad de registros	Porcentaje (%)
0	219	20.98
1	425	40.71
2	400	38.31



Perfil promedio resumido de clusters

Cluster	age	studytime	failures	absences	respuesta_positiva	origen_student-mat	origen_student-por
0	0.3758	-0.501	0.5577	0.3853	0.621	0.3562	0.6438
1	0.0312	0.0666	0.0202	-0.108	0.7765	0.32	0.68
2	-0.2389	0.2035	-0.3269	-0.0962	0.87	0.4525	0.5475

Los clusters permiten identificar grupos o perfiles de estudiantes con comportamientos similares. Sin embargo, si el Silhouette Score es bajo, los segmentos deben interpretarse con cautela.

9. Variable objetivo

Indicador	Valor
Variable objetivo	respuesta_positiva
Tipo de clasificación	Binaria
Número de clases	2
Valores nulos	0
Estado de validación	Apta

Distribución de clases

Clase	Cantidad	Porcentaje (%)
1	814	77.97
0	230	22.03

La variable objetivo fue validada para confirmar que posee clases suficientes y puede utilizarse en un problema de clasificación.

10. Partición entrenamiento, validación y prueba

Conjunto	Registros	Uso
Entrenamiento	730	Entrenar los modelos
Validación	157	Comparar modelos
Prueba	157	Evaluación final

Tipo de partición: 70/15/15 - Entrenamiento, validación y prueba

El conjunto de entrenamiento se utiliza para ajustar los modelos. El conjunto de validación permite comparar alternativas y seleccionar el mejor modelo. El conjunto de prueba se reserva para la evaluación final con datos no vistos.

11. Comparación de modelos

Resultados en validación

Modelo	Accuracy	F1-score	AUC
Baseline	0.7834	0.6883	0.5
Árbol de Decisión	0.7707	0.7654	0.6408
Random Forest	0.7771	0.7225	0.6834

Resultados en prueba

Modelo	Accuracy	F1-score	AUC
Baseline	0.7771	0.6796	0.5
Árbol de Decisión	0.7707	0.7595	0.6283
Random Forest	0.8089	0.7676	0.7559


Mejor modelo seleccionado: Árbol de Decisión

Se compararon modelos usando Accuracy, F1-score y AUC. El baseline sirve como punto mínimo de comparación, mientras que Árbol de Decisión y Random Forest permiten evaluar modelos predictivos más complejos.

12. Matriz de confusión


Clase real	Predicho: 0	Predicho: 1
Real: 0	13	22
Real: 1	14	108

Indicador	Valor
Total evaluado	157
Aciertos	121
Errores	36
Porcentaje aciertos	77.07
Porcentaje errores	22.93



13. Métricas de evaluación

Métrica	Valor
Accuracy	0.7707
Precision	0.7529
Recall	0.7707
F1-score	0.7595




El Accuracy indica el porcentaje total de aciertos. Precision mide qué tan confiables son las predicciones positivas. Recall indica cuántos casos positivos reales fueron detectados. F1-score resume el equilibrio entre Precision y Recall.

14. ROC comparativa

AUC por modelo


Modelo	AUC
Baseline	0.5
Árbol de Decisión	0.6283
Random Forest	0.7559



La curva ROC comparativa permite observar qué modelo separa mejor las clases. Un AUC más alto indica una mayor capacidad de diferenciación entre la clase positiva y negativa.

15. Curva ROC individual y AUC

Indicador	Valor
AUC	0.6283
Interpretación	Capacidad de separación baja



16. Interpretación gerencial

Para un equipo gerencial, el resultado puede comunicarse indicando que el modelo más recomendable es **Árbol de Decisión**, porque obtuvo el mejor equilibrio general entre aciertos y capacidad de clasificación. En el conjunto de prueba alcanzó un Accuracy de **0.7707**, un F1-score de **0.7595** y un AUC de **0.6283**. Esto significa que el modelo puede ayudar a identificar de manera más ordenada qué estudiantes tienen mayor probabilidad de presentar una respuesta positiva. Sin embargo, los resultados deben usarse como apoyo para la toma de decisiones, no como una decisión automática final.

17. Conclusión final

El sistema permitió ejecutar un flujo completo de análisis de datos y Machine Learning: carga y preparación del dataset, limpieza, transformación, segmentación mediante clustering, validación de variable objetivo, comparación de modelos, matriz de confusión, métricas y curvas ROC.

Aunque el modelo obtuvo un Accuracy aceptable, el AUC evidencia una capacidad de separación limitada. Por ello, los resultados deben considerarse una primera aproximación y no una decisión definitiva. Se recomienda mejorar la selección de variables, probar nuevos modelos y validar el desempeño con otros conjuntos de datos.